Kneser-Ney平滑

xuen

2013年11月28日

假定2元文法为 $\mathcal{R} = \{(w_r w_s) | 0 \leq r, s \leq N\}$ 其中 N为字典中词的数量,2元语法中词频排序表中第 k个数为:

$$n_k = \| \{ (w_r w_s) | f(w_r w_s) = k, \forall 0 \le r, s \le N \} \|$$
 (1)

那么KN平滑的概率如下计算:

$$P_{KN}(w_i|w_{i-1}) = \frac{\mathcal{A} + \mathcal{B} \cdot \mathcal{C}}{\sum\limits_{w_s} f(w_{i-1}w_s)}$$
 (2)

其中:

$$A = f(w_{i-1}w_i) - D(f(w_{i-1}w_i))$$
(3)

$$\mathcal{B} = D_1 \cdot \| \{ (w_{i-1}w_s) | f(w_{i-1}w_s) = 1 \} \|$$

$$+ D_2 \cdot \| \{ (w_{i-1}w_s) | f(w_{i-1}w_s) = 2 \} \|$$

$$+ D_{3+} \cdot \| \{ (w_{i-1}w_s) | f(w_{i-1}w_s) \ge 3 \} \|$$
 (4)

$$C = \frac{\| \{(w_r w_i) | f(w_r w_i) > 0\} \|}{\| \{(w_r w_s) | f(w_r w_s) > 0\} \|}$$
(5)

这里 $Y = \frac{n_1}{n_1 + 2n_2}$, $D_1 = 1 - 2Y \cdot \frac{n_2}{n_1}$, $D_2 = 1 - 3Y \cdot \frac{n_3}{n_2}$, $D_{3+} = 1 - 4Y \cdot \frac{n_4}{n_3}$, 另外:

$$D(\alpha) = \begin{cases} 0 & \alpha = 0, \\ D_1 & \alpha = 1, \\ D_2 & \alpha = 2, \\ D_{3+} & \alpha \ge 3. \end{cases}$$
 (6)